

Département : Intelligence Artificielle et Digitalisation

Filière : Sciences des Données, Big Data & Intelligence Artificielle

Rapport de Projet

Analyse de Web Mining appliquée au marché des compétences IA & Data

Sujet :

**Observatoire de Data Science et d'IA : ingénierie de la donnée et analyse prédictive de
l'évolution des compétences IA par le Web Mining**

Module : Analyse de Web / Web Mining (M242)

Encadré par :

Prof. Imad Sassi

Réalisé par :

AMAZIANE Nour El Houda

ADRAOU Ranya

ETTALBI Aya

BILOUL Ouiame

Année universitaire :

2025 – 2026

1. Introduction Générale

Le développement rapide de la Data Science, du Big Data et de l'Intelligence Artificielle a fortement transformé les besoins du marché de l'emploi. Les entreprises recherchent aujourd'hui des profils

capables de maîtriser des compétences variées, allant de l'analyse de données à l'ingénierie des données, en passant par le Machine Learning, le Cloud, le MLOps et les outils décisionnels.

Dans ce contexte, les offres d'emploi publiées en ligne représentent une source stratégique d'information. Elles permettent d'observer les compétences les plus demandées, les profils recherchés, les technologies dominantes et les tendances d'évolution du marché. Le Web Mining constitue ainsi une approche pertinente pour collecter, structurer et analyser ces données issues du Web.

Ce projet vise à construire un observatoire des compétences Data Science et Intelligence Artificielle à partir d'offres d'emploi collectées depuis plusieurs sources. Il s'appuie sur une chaîne complète allant de la collecte et du nettoyage des données jusqu'au stockage NoSQL, à l'analyse de contenu, à l'analyse de graphes, à la prédiction et à la visualisation interactive des résultats.

2. Problématique et objectifs

2.1 Problématique

Les compétences liées à la Data Science et à l'Intelligence Artificielle évoluent rapidement sous l'effet des nouvelles technologies, des besoins métiers et de la transformation numérique des entreprises. Cependant, les informations relatives à ces compétences sont dispersées dans de nombreuses offres d'emploi, souvent hétérogènes, incomplètes et non structurées.

La problématique de ce projet est donc la suivante :

Comment exploiter les offres d'emploi issues du Web afin d'identifier, analyser et prédire l'évolution des compétences Data Science et Intelligence Artificielle les plus demandées sur le marché ?

2.2 Objectifs

Ce projet a pour objectif de mettre en place un pipeline complet de Web Mining permettant de :

collecter et consolider des offres d'emploi Data/IA provenant de plusieurs sources ; nettoyer, standardiser et évaluer la qualité des données collectées ; stocker les données dans une base NoSQL adaptée aux données semi-structurées ; extraire et enrichir les compétences à partir du contenu des offres ; classer automatiquement les offres selon leurs domaines d'expertise ; analyser les relations entre compétences à travers un graphe de co-occurrence ; prédire l'évolution des compétences dans le temps ; présenter les résultats dans un dashboard interactif.

3. Architecture globale du projet

L'architecture du projet suit une chaîne complète de traitement des données issues du Web. Elle commence par la collecte des offres d'emploi à partir de plusieurs sources, puis par leur nettoyage et leur standardisation dans un schéma commun. Les données consolidées sont ensuite stockées dans MongoDB afin de gérer leur nature semi-structurée.

Le projet s'articule ensuite autour des trois axes principaux du Web Mining. Le Web Content Mining permet d'exploiter le contenu textuel des offres pour extraire les compétences, vectoriser les

descriptions et classer les domaines d'expertise. Le Web Structure Mining permet de modéliser les relations entre compétences sous forme de graphe et d'identifier les compétences centrales ainsi que les communautés. Le Web Usage Mining permet enfin d'analyser l'évolution temporelle des compétences et de construire des modèles prédictifs.

Les résultats de ces traitements sont intégrés dans un dashboard interactif afin de faciliter l'exploration et l'interprétation des tendances observées.



4. Collecte des données et sources utilisées

4.1 Présentation de la collecte

Dans ce projet, la collecte des données constitue une étape fondamentale, car elle permet de construire la base d'analyse des compétences Data Science et Intelligence Artificielle. Les données utilisées proviennent de plusieurs sources complémentaires : datasets publics, fichiers issus du scraping, plateformes spécialisées d'offres d'emploi et API.

L'objectif de cette phase est d'obtenir un ensemble de données suffisamment riche pour analyser les tendances du marché de l'emploi Data/IA selon plusieurs dimensions : les compétences demandées, les pays, les années, les types de postes, les modes de travail et les domaines d'expertise.

Les fichiers collectés présentent des structures différentes selon leur origine. Certains contiennent directement des colonnes de compétences, tandis que d'autres contiennent principalement des descriptions textuelles. Pour cette raison, une étape de standardisation a été nécessaire afin d'unifier les données dans un format commun exploitable.

4.2 Sources utilisées

Les sources retenues ont été sélectionnées selon plusieurs critères : la présence d'informations liées aux offres d'emploi, la disponibilité des compétences, la présence de dates, de pays et de titres de postes, ainsi que la pertinence par rapport aux domaines Data Science et Intelligence Artificielle.

fichier	type_source	periode	# nombre_lignes_utilisees	statut	raison
global_ai_jobs_dataset.csv	Dataset externe	2020-2026	120000	Gardé	Dataset historique global AI/Data avec skills
jobs_data_ai_clean.csv	Scraping multi-sources	2025-2026	274	Gardé	Offres récentes multi-plateformes, déjà nettoyées
kaggle_global_2025_data_science_jobs_skills_filtered.csv	Dataset Kaggle	2025	941	Gardé	Offres Data Science 2025 avec skills
linkedin_us_uk_canada_australia_2024-01-12_to_2024-01-17_data_ai_skills_filtered.csv	Dataset LinkedIn avec skills	2024-01-12 à 2024-01-17	5732	Gardé	Offres LinkedIn 2024 avec pays et skills
huggingface_global_2023_data_jobs_skills_filtered.csv	Dataset Hugging Face	2023	622067	Gardé	Grande base Data Jobs 2023 avec skills
linkedin_datastax_2023-12-05_to_2024-04-20_data_ai_filtered.csv	Dataset LinkedIn Hugging Face	2023-12-05 à 2024-04-20	1777	Gardé	Offres LinkedIn filtrées Data/AI avec descriptions
jobs_raw.json	API / scraping jobs	2026-04-15 à 2026-05-15	960	Gardé	Offres récentes Data/AI avec descriptions
aijobs_raw.csv	Scraping ai-jobs.net	2026	50	Gardé	Offres spécialisées AI jobs avec skills
remoteok_raw.csv	Scraping RemoteOK	2026	0	Ignoré	Pays non fiable ou absent

4.3 Critères de sélection des fichiers

Tous les fichiers collectés n'ont pas été intégrés automatiquement dans le dataset final. Chaque fichier a été analysé selon la disponibilité des colonnes essentielles : le titre du poste, le pays, la date de publication, les compétences, la source et le lien de l'offre lorsqu'il est disponible.

Les fichiers contenant des informations exploitables ont été conservés et standardisés. En revanche, certains fichiers ont été écartés lorsque les informations essentielles étaient absentes ou peu fiables. Par exemple, le fichier remoteok_raw.csv n'a pas été retenu dans le dataset final, car les informations relatives au pays étaient absentes ou insuffisamment fiables pour une analyse géographique correcte.

Cette sélection permet d'améliorer la cohérence du dataset final et de limiter les biais liés à des données incomplètes ou difficilement interprétables.

4.4 Couverture temporelle et géographique

Après la collecte et la fusion des sources retenues, le dataset final couvre une période allant de 2020 à 2026. Cette couverture temporelle permet d'analyser l'évolution des compétences Data/IA sur plusieurs années.

Les données couvrent également plusieurs pays, avec une forte représentation des marchés internationaux tels que les États-Unis, l'Inde, le Royaume-Uni, l'Allemagne, la France, le Canada et d'autres pays. Le Maroc est aussi présent dans le dataset, ce qui permet de réaliser un focus spécifique sur le marché marocain, même si sa représentation reste plus limitée par rapport aux grands marchés internationaux.

4.5 Résultat de la phase de collecte

La phase de collecte a permis de constituer un dataset consolidé de 751 801 offres d'emploi liées aux domaines Data Science, Big Data et Intelligence Artificielle. Ce volume important constitue une base pertinente pour mener les analyses suivantes : extraction des compétences, classification des domaines d'expertise, construction de graphes de compétences, modélisation prédictive et visualisation dans un dashboard interactif.

Cette étape a également permis de créer un fichier de compétences séparées, dans lequel chaque ligne représente une compétence associée à une offre. Ce fichier servira par la suite à l'analyse des skills, au Web Structure Mining et à la modélisation des tendances.

5. Nettoyage, standardisation et fusion

5.1 Objectif de la phase de préparation

Après la collecte, les fichiers obtenus présentaient des structures hétérogènes : noms de colonnes différents, formats de dates variés, pays écrits sous plusieurs formes, compétences représentées avec des formats différents et certaines colonnes fortement incomplètes.

L'objectif de cette phase est donc de transformer l'ensemble des fichiers collectés en un dataset final unique, cohérent et exploitable pour les étapes suivantes du projet : stockage NoSQL, Web Content Mining, Graph Mining, modélisation prédictive et dashboard interactif.

À l'issue de cette étape, le fichier final obtenu est :


final_data_ai_jobs_clean_2020_2026.csv

5.2 Standardisation du schéma des données

Les différentes sources ne possédaient pas la même structure. Par exemple, certaines utilisaient des colonnes comme title, titre_offre, job_title_clean ou encore job_title pour désigner le titre du poste. De la même manière, les compétences pouvaient être stockées dans des colonnes comme skills, job_skills, skills_tech_stack ou competences_detectees.

Afin de permettre la fusion, un schéma commun a été défini. Les colonnes équivalentes ont été renommées et alignées vers une structure unique contenant les informations essentielles pour l'analyse.

Les principales colonnes conservées sont :



Cette standardisation permet d'intégrer des fichiers provenant de sources différentes dans un dataset homogène.

5.3 Nettoyage des principales variables

Plusieurs traitements ont été appliqués afin d'améliorer la qualité et la cohérence des données.

Les dates ont été converties dans un format exploitable, puis les colonnes year, month et year_month ont été créées pour faciliter les analyses temporelles. Les pays ont été normalisés afin d'éviter les doublons sémantiques, par exemple en regroupant les variantes telles que US et United States.

Le champ remote_status a également été standardisé en modalités homogènes telles que Remote, Hybrid, On-site et Not specified. Les compétences ont été nettoyées afin d'uniformiser les séparateurs, supprimer les caractères inutiles et obtenir une représentation cohérente des skills.

Enfin, certaines colonnes très incomplètes ont été conservées uniquement lorsqu'elles apportaient une valeur analytique, ou écartées dans certaines versions réduites du dataset afin de faciliter l'exploitation.

5.4 Fusion des fichiers

Après la standardisation, les fichiers retenus ont été fusionnés dans un seul dataset consolidé. Chaque ligne représente une offre d'emploi liée à la Data Science, au Big Data ou à l'Intelligence Artificielle.

La fusion a été réalisée en conservant l'origine de chaque ligne grâce à la colonne original_file. Cette colonne permet de suivre la provenance des offres et de contrôler le poids de chaque source dans le dataset final.

Cette étape est importante, car elle permet de construire une base unique tout en gardant la traçabilité des données.

5.5 Résultat du dataset final

À la fin du processus de nettoyage, standardisation et fusion, le dataset final contient **751 801** offres d'emploi couvrant la période 2020-2026.

Indicateur	Valeur
Nombre total d'offres	751801
Nombre total de colonnes	30
Période couverte	2020-01-01 → 2026-05-06
Nombre d'années couvertes	7
Nombre de pays distincts	164
Nombre de sources intégrées	8
Nombre de plateformes	11
Nombre d'offres avec compétences	751476
Nombre d'offres sans compétences	325
Pourcentage d'offres avec compétences	99.96 %
Nombre de titres de postes distincts	179052
Nombre de modalités remote_status	4
Fichier final obtenu	final_data_ai_jobs_clean_2020_2026.csv

5.6 Contrôles effectués après fusion

Après la fusion, plusieurs vérifications ont été réalisées afin de s'assurer que le dataset final est exploitable. Les contrôles ont porté sur la présence des colonnes essentielles, les valeurs manquantes, les doublons, les années couvertes, les pays disponibles, les compétences et la répartition par source.

Les résultats montrent que les colonnes essentielles telles que job_title, country, date_posted, skills, source, platform et original_file sont suffisamment exploitables pour la suite du projet. Les éventuelles valeurs manquantes restantes seront prises en compte dans la partie dédiée au Data Quality Framework.

6. Data Quality Framework

6.1 Objectif de l'évaluation de la qualité

Avant d'exploiter le dataset dans les étapes de stockage, de Web Content Mining, de Graph Mining, de modélisation prédictive et de visualisation, une évaluation de la qualité des données a été réalisée. Cette étape permet de vérifier si les données sont suffisamment fiables, complètes et cohérentes pour supporter les analyses prévues.

Le Data Quality Framework mis en place repose sur plusieurs dimensions : la complétude des colonnes, la qualité des variables essentielles, la présence de doublons, les déséquilibres par

source, par année et par pays, ainsi que la qualité des compétences, des descriptions, des salaires et du statut de travail à distance.

6.2 Complétude des données

L'analyse des valeurs manquantes montre que certaines colonnes sont très bien renseignées, notamment les colonnes essentielles pour le projet : job_title, country, date_posted, skills, source, platform et original_file.

En revanche, certaines variables sont fortement incomplètes. C'est le cas de description, job_url, industry, salary_currency et salary. Ces colonnes ont donc été considérées avec prudence. Une version réduite du dataset a été créée en supprimant les colonnes les plus incomplètes afin de faciliter les analyses principales.

Les colonnes essentielles restent toutefois suffisamment complètes pour permettre l'analyse des compétences Data/IA.

	missing_count	missing_percent
description	748740	99.59
job_url	743008	98.83
industry	630860	83.91
salary_currency	630308	83.84
salary	610543	81.21
job_type	130543	17.36
company_name	120030	15.97
education_required	9698	1.29
tools_used	8793	1.17
experience_level	1631	0.22
city	1246	0.17
date_posted	1240	0.16
remote_status_original	1206	0.16
skills_clean	325	0.04
skills	325	0.04
country	265	0.04
country_clean	265	0.04
skills_original	124	0.02
month	6	0.00
year_month	6	0.00
remote_status_clean	0	0.00
original_file	0	0.00
source	0	0.00
category	0	0.00
platform	0	0.00
remote_status	0	0.00
year	0	0.00
job_title	0	0.00
job_id	0	0.00
job_category_clean	0	0.00

6.3 Qualité des colonnes essentielles

Les colonnes nécessaires aux analyses principales présentent une bonne qualité globale. Le titre du poste est disponible pour toutes les offres, les informations de source et de plateforme sont complètes, et la colonne skills est renseignée pour la quasi-totalité des lignes.

Les résultats montrent que le dataset contient 751 476 offres avec compétences, contre seulement 325 offres sans compétences, soit 99,96 % d'offres avec skills. Cette forte disponibilité des compétences rend le dataset particulièrement adapté à l'analyse des skills, au Web Content Mining et au Graph Mining.

Les dates et les pays sont également globalement exploitables, malgré un faible nombre de valeurs manquantes.

	missing_count	missing_percent	non_null_count
job_title	0	0.00	751801
country	265	0.04	751536
date_posted	1240	0.16	750561
skills	325	0.04	751476
source	0	0.00	751801
platform	0	0.00	751801
original_file	0	0.00	751801

6.4 Analyse des doublons

L'analyse des doublons exacts montre qu'aucune ligne strictement identique n'est présente dans le dataset final. Cela indique que la phase de fusion n'a pas généré de répétitions exactes.

Cependant, des doublons potentiels ont été détectés sur la base de la combinaison job_title, country, date_posted et source. Ces cas ne sont pas nécessairement de vrais doublons, car plusieurs offres peuvent partager le même titre, le même pays et la même date tout en correspondant à des entreprises ou à des postes différents. Ils sont donc considérés comme des doublons potentiels et non comme des erreurs confirmées.

6.5 Déséquilibre par source

L'analyse de la répartition par source montre un déséquilibre important. Le fichier Hugging Face 2023 représente la majorité des offres, avec 622 067 lignes, soit environ 82,74 % du dataset. Le dataset global_ai_jobs_dataset.csv représente environ 15,96 % des données. Les autres sources apportent des volumes plus faibles, mais elles permettent d'enrichir la base avec des offres plus récentes ou issues de plateformes spécialisées.

Ce déséquilibre doit être pris en compte lors de l'interprétation des résultats, car les tendances observées peuvent être influencées par la source dominante.

	original_file	number_of_jobs	percentage
0	huggingface_global_2023_data_jobs_skills_filte...	622067	82.74
1	global_ai_jobs_dataset.csv	120000	15.96
2	linkedin_us_uk_canada_australia_2024-01-12_to_...	5732	0.76
3	linkedin_datastax_2023-12-05_to_2024-04-20_dat...	1777	0.24
4	jobs_raw.json	960	0.13
5	kaggle_global_2025_data_science_jobs_skills_fi...	941	0.13
6	jobs_data_ai_clean.csv	274	0.04
7	aijobs_raw.csv	50	0.01

6.6 Déséquilibre temporel

Le dataset couvre la période 2020–2026, mais la distribution temporelle n’est pas équilibrée. L’année 2023 domine fortement avec 641 784 offres, soit environ 85,37 % du dataset. Les autres années sont beaucoup moins représentées.

Ce déséquilibre temporel est principalement lié à la présence du fichier Hugging Face 2023, qui constitue la source la plus volumineuse. Pour cette raison, les analyses temporelles et les modèles prédictifs doivent être interprétés avec prudence. Il est préférable d’utiliser des fréquences relatives plutôt que des volumes bruts lorsque l’objectif est d’étudier l’évolution des compétences dans le temps.

	year	number_of_jobs	percentage
0	2020	20010	2.66
1	2021	20175	2.68
2	2022	19872	2.64
3	2023	641784	85.37
4	2024	27642	3.68
5	2025	20985	2.79
6	2026	1333	0.18

6.7 Déséquilibre géographique

L’analyse géographique montre que le dataset couvre un grand nombre de pays, mais avec une forte concentration sur certains marchés. Les États-Unis sont le pays le plus représenté avec

199 743 offres, soit environ 26,57 % du dataset. Ils sont suivis par l'Inde, le Royaume-Uni, l'Allemagne, la France, Singapour et les Pays-Bas.

Le dataset présente donc une couverture internationale intéressante, mais il reste géographiquement déséquilibré. Les résultats globaux reflètent davantage les marchés les plus représentés.

Le Maroc est présent dans le dataset avec 1 058 offres, ce qui permet un focus spécifique, mais son volume reste faible par rapport aux grands marchés internationaux.

	country	number_of_jobs	percentage
0	United States	199743	26.57
1	India	56012	7.45
2	United Kingdom	46123	6.14
3	Germany	33488	4.45
4	France	32273	4.29
5	Singapore	31216	4.15
6	Netherlands	28268	3.76
7	Canada	25601	3.41
8	Australia	21516	2.86
9	Spain	20278	2.70
10	Sudan	19175	2.55
11	Brazil	16980	2.26
12	Japan	13322	1.77
13	Italy	12750	1.70
14	Mexico	11785	1.57
15	Portugal	11237	1.49
16	Poland	11092	1.48
17	South Africa	9346	1.24
18	Belgium	9175	1.22
19	Philippines	9158	1.22
20	Switzerland	7811	1.04
21	Ireland	7598	1.01
22	Austria	6578	0.87
23	Malaysia	6560	0.87
24	Argentina	6188	0.82
25	Hong Kong	5701	0.76
26	Chile	5543	0.74
27	United Arab Emirates	5085	0.68
28	Colombia	4971	0.66
29	Denmark	4929	0.66

6.8 Qualité des compétences

La colonne skills présente une très bonne qualité globale. Elle est renseignée pour 99,96 % des offres, avec une moyenne d'environ 5,31 compétences par offre et une médiane de 4 compétences par offre.

Cette forte disponibilité des compétences constitue un point fort du dataset, car elle permet de construire le fichier `skills_exploded`, d'analyser les compétences les plus demandées, de construire des graphes de co-occurrence et de générer des vecteurs de compétences pour les étapes de modélisation.

6.9 Qualité des descriptions et des salaires

Les colonnes `description` et `salary` sont fortement incomplètes. La colonne `description` est manquante dans 99,59 % des lignes, tandis que la colonne `salary` est manquante dans 81,21 % des lignes. Ces deux variables ne peuvent donc pas être utilisées comme base principale d'analyse pour l'ensemble du dataset.

Cependant, les descriptions disponibles restent utiles pour démontrer des traitements de Web Content Mining, notamment l'extraction complémentaire de compétences à partir des textes non structurés. Les salaires, en revanche, doivent être interprétés avec beaucoup de prudence et ne constituent pas une variable centrale dans ce projet.

6.10 Qualité du remote status

La variable `remote_status` a été standardisée afin d'obtenir des modalités homogènes. La majorité des offres sont classées comme On-site, avec 608 492 offres soit 80,94 % du dataset. Les offres Remote représentent 13,42 %, les offres Hybrid 5,33 %, et les offres Not specified 0,31 %.

Cette variable est donc exploitable pour analyser les modes de travail associés aux offres Data/IA.

	remote_status	number_of_jobs	percentage
0	On-site	608492	80.94
1	Remote	100902	13.42
2	Hybrid	40077	5.33
3	Not specified	2330	0.31

6.11 Synthèse du Data Quality Framework

dimension	evaluation	commentaire
Titres des postes	Très bonne	La colonne job_title est complète.
Pays	Bonne	Très peu de pays manquants après nettoyage.
Dates	Très bonne	Très peu de dates manquantes.
Compétences	Très bonne	La grande majorité des offres contient des skills.
Sources	Très bonne	La source et le fichier d'origine sont disponibles pour toutes les lignes.
Remote status	Bonne	Remote status normalisé en Remote, Hybrid, On-site et Not specified.
Descriptions	Faible dans le fichier original	La colonne description a été supprimée de la version réduite car très incomplète.
Salaires	Faible	La colonne salaire reste très incomplète.
Équilibre temporel	Déséquilibré	L'année 2023 est dominante à cause du volume Hugging Face.
Équilibre géographique	Déséquilibré	Les États-Unis et les grands pays anglophones sont fortement représentés.
Équilibre des sources	Déséquilibré	Certaines sources contiennent beaucoup plus de lignes que d'autres.

6.12 Conclusion de l'axe

Le Data Quality Framework montre que le dataset final est globalement exploitable pour les objectifs du projet. Les colonnes essentielles, notamment les titres de postes, les pays, les dates, les compétences et les sources, présentent une bonne qualité. La colonne skills constitue un point fort majeur, car elle est disponible pour presque toutes les offres.

Cependant, plusieurs limites doivent être prises en compte. Le dataset est fortement déséquilibré par source, par année et par pays. L'année 2023 et la source Hugging Face dominant largement les données. De plus, les descriptions et les salaires sont très incomplets. Ces limites n'empêchent pas l'exploitation du dataset, mais elles imposent une interprétation prudente des résultats, notamment pour les analyses temporelles, géographiques et prédictives.

Pour limiter ces biais, les analyses suivantes privilégient les indicateurs relatifs, les comparaisons contrôlées et une interprétation orientée tendance plutôt qu'une lecture uniquement basée sur les volumes bruts.

7. Stockage NoSQL avec MongoDB

7.1 Objectif du stockage NoSQL

Après la phase de nettoyage, de standardisation et d'évaluation de la qualité des données, le dataset final a été stocké dans une base NoSQL afin de répondre aux exigences techniques du projet. L'objectif de cette étape est de mettre en place une architecture de stockage flexible, adaptée aux données issues du Web Mining.

Les offres d'emploi collectées proviennent de sources différentes et présentent une structure semi-structurée : certaines colonnes peuvent varier selon l'origine des données, certaines informations sont absentes pour certaines offres, et les compétences peuvent être représentées sous forme de listes. MongoDB constitue donc un choix adapté, car il permet de

stocker les données sous forme de documents proches du format JSON, tout en offrant une grande flexibilité pour les requêtes analytiques.

7.2 Justification du choix de MongoDB

MongoDB a été utilisé pour stocker les données nettoyées, car il est particulièrement adapté aux données hétérogènes et semi-structurées. Contrairement à une base relationnelle classique, MongoDB ne nécessite pas un schéma strict fixe pour toutes les lignes. Cette flexibilité est pertinente dans le cadre de ce projet, puisque les offres d'emploi proviennent de plusieurs plateformes et ne possèdent pas toujours exactement les mêmes informations.

De plus, MongoDB permet d'effectuer rapidement des requêtes sur des champs clés comme le pays, l'année, le statut de travail à distance, la source ou encore les compétences. Il permet aussi de stocker les compétences sous forme de listes, ce qui facilite les recherches du type : offres contenant Python, offres contenant SQL, ou encore compétences les plus fréquentes par pays.

7.3 Architecture de la base MongoDB

La base MongoDB créée dans ce projet est nommée : `data_ai_jobs_db`

Elle contient deux collections principales :

- `jobs_clean` : Offres d'emploi nettoyées et consolidées
(une ligne correspond à une offre d'emploi)
- `skills_explored` : Compétences extraites et séparées individuellement
(une ligne correspond à une compétence associée à une offre)

La collection `jobs_clean` permet d'analyser les offres selon les dimensions principales : pays, année, source, mode de travail, titre du poste et compétences.

La collection `skills_explored` permet d'effectuer des analyses plus fines sur les compétences, notamment le calcul des compétences les plus fréquentes, les skills par pays et les skills par année.

7.4 Préparation des données avant insertion

Avant l'insertion dans MongoDB, les données ont été préparées afin d'être compatibles avec le format document. Les dates ont été converties dans un format lisible, les valeurs manquantes ont été remplacées par `None`, et la colonne des compétences a été transformée en liste dans une nouvelle variable exploitable pour les requêtes.

Par exemple, une offre contenant :

```
skills = python, sql, spark
```

est transformée en :


```
skills_list = ["python", "sql", "spark"]
```

Cette transformation permet ensuite d'effectuer facilement des requêtes MongoDB sur les compétences, par exemple pour trouver toutes les offres contenant python.

7.5 Insertion des données dans MongoDB

L'insertion des données a été réalisée à partir du notebook **05_mongodb_storage.ipynb**. Pour éviter les problèmes de mémoire, les données ont été insérées par lots. Cette méthode permet de gérer efficacement un volume important de données.

Après insertion, les résultats obtenus sont les suivants :



The screenshot shows the MongoDB Compass interface. On the left, the 'CONNECTIONS' panel lists 'MongoDB Local' with a tree view showing 'data_ai_jobs_db' selected. The main panel displays the 'data_ai_jobs_db' database with a table of collections. The table has columns: Collection name, Properties, Storage size, Data size, Documents, Avg. document size, Indexes, and Total index size. Two collections are listed: 'jobs_clean' and 'skills_exploded'.

Collection name	Properties	Storage size	Data size	Documents	Avg. document size	Indexes	Total index size
jobs_clean	-	232.16 MB	832.42 MB	752K	1.11 kB	6	45.27 MB
skills_exploded	-	258.50 MB	1.85 GB	4M	463.00 B	4	108.14 MB

Ces résultats confirment que les deux datasets principaux ont bien été intégrés dans MongoDB.

7.6 Vérification et requêtes MongoDB

Après l'insertion, plusieurs requêtes ont été exécutées afin de vérifier la cohérence des données stockées et de produire des indicateurs analytiques.

Les principales requêtes réalisées sont les suivantes :

Requête	Résultat
Nombre total d'offres	751 801
Nombre total de compétences mentionnées	3 991 435
Nombre d'offres au Maroc	1 058
Nombre d'offres Remote	100 902
Nombre d'offres contenant Python	416 081

Ces requêtes montrent que les données sont bien exploitables dans MongoDB et que la base permet d'interroger efficacement le dataset selon plusieurs dimensions.

7.7 Exemples de résultats analytiques

L'analyse des données stockées dans MongoDB a permis de retrouver les principales tendances déjà observées dans les notebooks de préparation. Par exemple, la répartition des offres par année montre une forte concentration en 2023, ce qui confirme le déséquilibre temporel identifié dans le Data Quality Framework.

	year	number_of_jobs
0	2020	20010
1	2021	20175
2	2022	19872
3	2023	641784
4	2024	27642
5	2025	20985
6	2026	1333

MongoDB a également permis d'obtenir la répartition des offres par pays. Les États-Unis sont le pays le plus représenté, suivis par l'Inde, le Royaume-Uni, l'Allemagne et la France.

	country	number_of_jobs
0	United States	199743
1	India	56012
2	United Kingdom	46123
3	Germany	33488
4	France	32273
5	Singapore	31216
6	Netherlands	28268
7	Canada	25601
8	Australia	21516
9	Spain	20278
10	Sudan	19175
11	Brazil	16980
12	Japan	13322
13	Italy	12750
14	Mexico	11785
15	Portugal	11237
16	Poland	11092
17	South Africa	9346
18	Belgium	9175
19	Philippines	9158

La collection skills_exploded a aussi permis d'identifier les compétences les plus fréquentes dans l'ensemble du dataset.

	skill	number_of_mentions
0	sql	423016
1	python	416081
2	aws	133924
3	r	131196
4	tableau	126609
5	excel	124313
6	azure	123904
7	spark	112002
8	power bi	97363
9	tensorflow	81587
10	java	75943
11	pytorch	75727
12	hadoop	63677
13	scala	55324
14	snowflake	54116
15	databricks	52207
16	machine learning	51441
17	data analysis	50660
18	deep learning	48987
19	statistics	48874
20	computer vision	48523

7.8 Indexation des collections

Afin d'améliorer les performances des requêtes, plusieurs index ont été créés sur les champs les plus utilisés. Les index concernent notamment les champs country, year, remote_status, original_file, skills_list dans la collection jobs_clean, ainsi que skill, country et year dans la collection skills_exploded.

Cette indexation permet d'accélérer les recherches fréquentes, par exemple les offres par pays, les offres par année ou les offres contenant une compétence donnée.

8. Web Content Mining

8.1 Objectif de l'axe

Le Web Content Mining constitue une étape centrale du projet, car il permet d'exploiter le contenu textuel des offres d'emploi afin d'en extraire des informations utiles pour l'analyse du marché Data/IA.

Dans ce projet, cet axe vise principalement à enrichir les compétences associées aux offres, transformer les descriptions en représentations numériques, appliquer des techniques NLP et classer automatiquement les offres selon leurs domaines d'expertise.

L'objectif est donc de passer d'un contenu textuel non structuré, notamment les descriptions des offres, à des informations structurées exploitables pour les étapes suivantes : analyse des compétences, Graph Mining, modélisation prédictive et dashboard interactif.

8.2 Données textuelles exploitées

Les données non structurées utilisées dans cette partie correspondent principalement aux descriptions des offres d'emploi. Ces descriptions contiennent des informations importantes sur les missions, les compétences techniques, les outils utilisés et les profils recherchés.

Cependant, toutes les offres ne disposent pas d'une description exploitable. Dans le dataset final, 3 061 offres contiennent une description suffisamment renseignée. Pour éviter d'introduire du bruit, l'extraction complémentaire des compétences a été appliquée uniquement à ces descriptions.

Les offres ne disposant pas de description conservent leurs compétences initiales présentes dans la colonne skills.

8.3 Extraction et enrichissement des compétences

La colonne skills du dataset final contient déjà les compétences principales associées aux offres. Elle est donc considérée comme la référence de départ.

Dans le cadre du Web Content Mining, une extraction complémentaire a été réalisée à partir des descriptions disponibles. Un dictionnaire de compétences a été construit à partir du dataset skills_exploded, puis appliqué aux descriptions nettoyées afin de détecter les compétences mentionnées dans le texte.

Les résultats obtenus montrent que, parmi les 3 061 descriptions exploitables, 3 047 descriptions contiennent au moins une compétence détectée automatiquement.

Les compétences extraites depuis les descriptions ont ensuite été fusionnées avec les compétences existantes afin de créer une version enrichie. Les doublons ont été supprimés afin d'éviter la répétition des mêmes compétences.

8.4 Démonstration Transformer / NER

Afin de répondre à l'exigence du projet liée aux modèles **Transformers** et à la reconnaissance d'entités nommées (**NER**), un modèle NER orienté compétences a été intégré dans le pipeline de Web Content Mining. L'objectif de cette étape est d'identifier automatiquement, à partir des descriptions d'offres d'emploi, des entités pouvant correspondre à des compétences techniques ou à des éléments liés aux profils recherchés.

Le modèle Transformer a été appliqué sur un échantillon de descriptions nettoyées. Cette approche permet de compléter l'extraction basée sur dictionnaire par une méthode NLP plus avancée, capable d'analyser le contenu textuel de manière contextuelle.

L'exécution de cette partie a été réalisée avec succès. Les entités détectées ont été stockées dans un fichier de sortie dédié, permettant de conserver les résultats du modèle NER et de les exploiter pour l'analyse des compétences extraites depuis les descriptions.

Cette étape confirme la faisabilité de l'intégration de modèles Transformers dans le pipeline proposé et renforce la dimension sémantique de l'analyse du contenu des offres d'emploi.

8.5 Vectorisation TF-IDF des descriptions

Après le nettoyage des descriptions, une vectorisation TF-IDF a été appliquée afin de transformer les textes en représentations numériques. Cette méthode permet d'identifier les termes les plus représentatifs du corpus de descriptions.

La vectorisation a été réalisée sur les 3 061 descriptions exploitables, avec une matrice finale de dimension : 3061×2000

Cela signifie que chaque description est représentée par un vecteur numérique basé sur les 2 000 termes les plus pertinents.

Les termes les plus importants obtenus sont liés aux notions suivantes :

data, experience, ai, work, business, learning, team, skills, machine learning, engineering

8.6 Vectorisation des compétences

Les compétences enrichies ont ensuite été transformées en vecteurs binaires à l'aide de MultiLabelBinarizer. Cette étape permet de représenter chaque offre par un vecteur de compétences.

Chaque compétence devient une colonne, et chaque offre reçoit une valeur :

1 si la compétence est présente
0 sinon

Pour éviter une matrice trop large, les 100 compétences les plus fréquentes ont été retenues. La matrice obtenue a la dimension suivante : 751801×100

	sql	python	aws	r	tableau	excel	azure	spark	power bi	tensorflow	...	bitbucket	db2	splunk	mongo	redis	flask	plotly	perl	css	seaborn
0	1		1	0	0	0	0	0	0	0	...	0	0	0	0	0	0	0	0	0	0
1	0		0	0	0	0	0	0	0	0	...	0	0	0	0	0	0	0	0	0	0
2	0		1	0	0	0	0	0	0	0	...	0	0	0	0	0	0	0	0	0	0
3	0		1	0	0	0	0	0	0	1	...	0	0	0	0	0	0	0	0	0	0
4	1		0	0	0	0	0	0	0	0	...	0	0	0	0	0	0	0	0	0	0

8.7 Embeddings Transformer des descriptions

En complément de TF-IDF, des embeddings sémantiques ont été générés à l'aide d'un modèle Sentence Transformer. Contrairement à TF-IDF, qui repose principalement sur la fréquence des mots, les embeddings permettent de représenter le sens global d'un texte.

Les embeddings ont été calculés sur un échantillon de 1 000 descriptions afin de limiter le temps d'exécution. Le modèle utilisé produit des vecteurs de dimension 384.

8.8 Classification automatique des domaines d'expertise

Une classification automatique a été mise en place afin d'affecter chaque offre à un domaine d'expertise. La classification repose sur le titre du poste, les descriptions disponibles et les compétences enrichies.

expertise_domain	number_of_jobs	percentage
Data Engineering	219296	29.17
Data Analysis / BI	193983	25.8
Machine Learning / AI	153308	20.39
Data Science	87358	11.62
MLOps / Cloud Data	59802	7.95
Other Data / AI	32473	4.32
Database / Data Warehouse	5581	0.74

8.9 Focus sur le marché marocain

Un focus spécifique a été réalisé sur les offres localisées au Maroc afin d'observer la répartition des domaines d'expertise dans ce marché.

Le dataset contient 1 058 offres localisées au Maroc.

	expertise_domain	number_of_jobs	percentage
0	Data Engineering	361	34.12
1	Data Analysis / BI	299	28.26
2	MLOps / Cloud Data	148	13.99
3	Machine Learning / AI	102	9.64
4	Data Science	87	8.22
5	Other Data / AI	58	5.48
6	Database / Data Warehouse	3	0.28

8.10 Conclusion de l'axe Web Content Mining

Le Web Content Mining a permis d'enrichir et de structurer les informations textuelles contenues dans les offres d'emploi. Les compétences existantes ont été conservées comme base principale, puis complétées à partir des descriptions disponibles. Cette approche permet d'améliorer la qualité de la représentation des compétences sans introduire de bruit provenant des titres de postes.

La vectorisation TF-IDF, la génération de vecteurs de compétences et les embeddings Transformer ont permis de transformer les contenus textuels en représentations numériques exploitables. Enfin, la classification automatique des domaines d'expertise a fourni une vision structurée du marché Data/IA, en distinguant les grands domaines comme le Data Engineering, la Data Analysis/BI, le Machine Learning/AI et le MLOps.

Cette partie prépare directement les étapes suivantes du projet, notamment le Graph Mining, la prédiction des tendances et la visualisation dans le dashboard interactif.

9. Web Structure Mining / Graph Mining


Le Web Structure Mining constitue l'un des axes fondamentaux du Web Mining. Cette approche permet d'analyser les relations existantes entre les différentes compétences technologiques extraites des offres d'emploi afin de comprendre la structure globale du marché de l'emploi en Intelligence Artificielle et Data Science. Dans ce projet, les compétences identifiées à partir des descriptions de postes ont été modélisées sous forme de graphe complexe où chaque nœud représente une compétence technologique et chaque arête représente une relation de co-occurrence entre deux compétences apparaissant simultanément dans une même offre d'emploi. Cette modélisation permet d'identifier les technologies les plus influentes, les dépendances technologiques ainsi que les principaux écosystèmes métiers dominants dans le marché actuel.

9.1 Graphe de co-occurrence

Afin de construire le graphe de compétences, une matrice de co-occurrence a été générée à partir des compétences extraites lors de la phase de Web Content Mining. Chaque fois que deux compétences apparaissaient ensemble dans une même offre d'emploi, une connexion était créée entre elles. Le poids des arêtes augmente en fonction de la fréquence d'apparition conjointe des compétences.

	skill	aws	azure	data analysis	databricks	deep learning	excel	hadoop	java	machine learning	...	python	pytorch	r	scala	snowflake	spark	sql	statistics	tableau	tensorflow
0	aws	0	54255	9484	18167	9531	7627	25210	29597	10122	...	106118	18549	22971	24917	27113	48125	91232	9391	24345	19446
1	azure	54255	0	8688	36423	8723	8109	20230	22250	9128	...	87903	15204	21469	21172	19801	40426	89707	8530	19287	16707
2	data analysis	9484	8688	0	3600	16312	9459	4572	5559	16566	...	34581	17471	10137	3970	3715	8022	35144	16515	9848	17735
3	databricks	18167	36423	3600	0	3511	2976	7425	8110	3717	...	40242	5491	8484	10706	10813	23313	39421	3560	8232	5979
4	deep learning	9531	8723	16312	3511	0	9004	4552	5457	16730	...	33947	17718	9546	3983	3590	8057	33900	16084	8987	17960
5	excel	7627	8109	9459	2976	9004	0	4283	4738	9134	...	48117	9931	23896	2430	4210	5537	70326	9047	35657	10483
6	hadoop	25210	20230	4572	7425	4552	4283	0	23359	4938	...	51231	7966	17535	20831	8432	47339	45777	4579	13575	9501
7	java	29597	22250	5559	8110	5457	4738	23359	0	6014	...	66407	8992	18269	30085	10666	33647	50913	5458	12808	10638
8	machine learning	10122	9128	16566	3717	16730	9134	4938	6014	0	...	35538	17991	10329	4371	3945	8678	35105	16393	9484	18501
9	power bi	12962	26675	7374	10107	6912	30847	6155	6147	7168	...	52627	8245	25339	4623	8367	10304	71623	6899	44946	8813
10	python	106118	87903	34581	40242	33947	48117	51231	66407	35538	...	0	56675	120696	48964	39592	92895	270906	33946	83211	61830
11	pytorch	18549	15204	17471	5491	17718	9931	7966	8992	17991	...	56675	0	16433	6675	4706	14764	45127	17433	11876	38234
12	r	22971	21469	10137	8484	9546	23896	17535	18269	10329	...	120696	16433	0	14185	7031	24564	94588	9907	43606	20123
13	scala	24917	21172	3970	10706	3983	2430	20831	30085	4371	...	48964	6675	14185	0	8849	37162	38854	3963	7802	8616
14	snowflake	27113	19801	3715	10813	3590	4210	8432	10666	3945	...	39592	4706	7031	8849	0	15930	43633	3657	14116	4920
15	spark	48125	40426	8022	23313	8057	5537	47339	33647	8678	...	92895	14764	24564	37162	15930	0	78770	8057	17743	18038
16	sql	91232	89707	35144	39421	33900	70326	45777	50913	35105	...	270906	45127	94588	38854	43633	78770	0	34031	98265	48260
17	statistics	9391	8530	16515	3560	16084	9047	4579	5458	16393	...	33946	17433	9907	3963	3657	8057	34031	0	9268	17690
18	tableau	24345	19287	9848	8232	8987	35657	13575	12808	9484	...	83211	11876	43606	7802	14116	17743	98265	9268	0	13379
19	tensorflow	19446	16707	17735	5979	17960	10483	9501	10638	18501	...	61830	38234	20123	8616	4920	18038	48260	17690	13379	0

Graphe NetworkX de co-occurrence des compétences IA/Data



Le graphe obtenu a été construit à l'aide de la bibliothèque NetworkX de Python. Cette représentation permet de visualiser les relations entre technologies et d'identifier les compétences qui sont fréquemment associées dans les offres d'emploi du domaine IA et Data Science.


L'analyse du graphe révèle plusieurs relations fortes entre les compétences. Par exemple, Python apparaît fortement connecté avec Machine Learning, Deep Learning et TensorFlow, ce qui confirme son rôle central dans l'écosystème IA moderne. De même, AWS, Docker et Kubernetes présentent des connexions importantes, traduisant la forte demande des architectures Cloud et MLOps dans les environnements de production IA.

Cette analyse met également en évidence l'existence de dépendances technologiques entre compétences. Certaines technologies sont rarement demandées seules et apparaissent principalement dans des combinaisons spécifiques, ce qui reflète les compétences hybrides recherchées par les entreprises.

9.2 Algorithme PageRank

Afin d'identifier les compétences les plus influentes du réseau de co-occurrence, l'algorithme PageRank a été appliqué sur le graphe des compétences construit précédemment. Initialement développé pour le classement des pages web, cet algorithme permet ici de mesurer l'importance relative de chaque compétence dans l'écosystème IA/Data en fonction de ses connexions avec les autres technologies du réseau.

Le principe du PageRank repose sur le fait qu'une compétence devient importante lorsqu'elle est fortement connectée à d'autres compétences elles-mêmes importantes. Les technologies les plus centrales du marché obtiennent ainsi les scores PageRank les plus élevés.



Les résultats obtenus montrent que Python possède le score PageRank le plus élevé, confirmant son rôle dominant dans les métiers de la Data Science, du Machine Learning et de l'Intelligence Artificielle. SQL apparaît également comme une compétence fondamentale fortement connectée aux environnements Big Data, Cloud et analyse de données.

Les technologies AWS, Spark et Azure présentent également des scores élevés, traduisant l'importance croissante des infrastructures Cloud Computing et du traitement distribué des données dans les projets IA modernes. Des outils comme TensorFlow, Tableau et Power BI apparaissent aussi parmi les compétences centrales du réseau, montrant leur forte intégration dans les domaines de l'analyse avancée, du Deep Learning et de la Business Intelligence.

Cette analyse permet ainsi d'identifier les compétences stratégiques qui constituent aujourd'hui les principaux piliers technologiques du marché de l'emploi IA/Data.

9.3 Détection de communautés avec Louvain

Afin d'identifier les groupes de compétences fortement liées entre elles, l'algorithme de détection de communautés Louvain a été appliqué sur le graphe de co-occurrence des compétences. Cet algorithme permet de partitionner automatiquement le réseau en plusieurs communautés en maximisant la modularité du graphe.

Le principe de l'algorithme Louvain consiste à regrouper les compétences qui possèdent un grand nombre de connexions internes tout en limitant les connexions avec les autres groupes. Cette approche

permet de révéler la structure organisationnelle cachée du réseau et de mettre en évidence les principaux écosystèmes technologiques présents dans les offres d'emploi IA/Data.

Communautés détectées par l'algorithme Louvain



Les résultats obtenus montrent l'existence de plusieurs communautés technologiques distinctes. Une première communauté regroupe principalement les technologies liées au Cloud Computing et au Big Data telles que AWS, Azure, Spark, Hadoop, Databricks, Scala et Java. Cette communauté met en évidence l'importance des infrastructures distribuées et des environnements de traitement massif des données dans les projets IA modernes.

Une seconde communauté rassemble davantage les compétences orientées Intelligence Artificielle, Machine Learning et analyse de données, notamment Python, TensorFlow, PyTorch, Deep Learning, Machine Learning, SQL, Tableau, Power BI, Excel et Statistics. Cette communauté représente le cœur des activités de Data Science, d'analyse avancée et de visualisation décisionnelle.

Les résultats montrent également que certaines compétences comme Python, SQL et AWS jouent un rôle de liaison entre plusieurs communautés, traduisant leur caractère transversal dans l'écosystème technologique actuel.

Cette analyse met ainsi en évidence la forte spécialisation des compétences recherchées sur le marché de l'emploi IA/Data ainsi que les relations structurelles existant entre les domaines du Cloud, du Big Data, du Machine Learning et de la Business Intelligence.

9.4 Interprétation des communautés

L'analyse des communautés détectées par l'algorithme Louvain permet de mieux comprendre l'organisation structurelle des compétences dans l'écosystème IA/Data. Les résultats montrent que les technologies ne sont pas réparties de manière aléatoire dans le réseau, mais qu'elles forment des groupes cohérents correspondant à des domaines technologiques spécifiques.

La communauté regroupant AWS, Azure, Spark, Hadoop, Databricks, Scala et Java représente principalement l'écosystème Cloud Computing et Big Data. Ces technologies sont fortement utilisées dans les architectures distribuées, le traitement massif des données et les infrastructures cloud nécessaires aux projets d'intelligence artificielle modernes. Leur forte interconnexion traduit l'importance croissante des environnements Big Data dans les entreprises manipulant de grands volumes de données.

La seconde communauté, composée notamment de Python, TensorFlow, PyTorch, Machine Learning, Deep Learning, SQL, Tableau et Power BI, correspond davantage au domaine de la Data Science et de l'Intelligence Artificielle. Cette communauté regroupe les outils utilisés pour le développement des modèles IA, l'analyse avancée des données, la visualisation décisionnelle et l'apprentissage automatique.

L'analyse met également en évidence le rôle central de certaines compétences transversales comme Python, SQL et AWS, qui servent de pont entre plusieurs communautés technologiques. Ces compétences apparaissent comme des technologies clés capables de connecter les environnements Cloud, Big Data et Intelligence Artificielle.

Ces résultats confirment que le marché de l'emploi IA/Data repose sur des profils hybrides combinant plusieurs domaines technologiques simultanément. Les entreprises recherchent de plus en plus des compétences capables d'intégrer l'analyse de données, l'intelligence artificielle et les infrastructures cloud dans un même environnement professionnel.

10. Web Usage Mining / Analyse prédictive

Le Web Usage Mining consiste à analyser l'évolution temporelle des données afin d'identifier les tendances du marché et de prévoir les comportements futurs. Dans le cadre de ce projet, cette approche a été utilisée pour étudier l'évolution des compétences technologiques dans les offres d'emploi liées à l'Intelligence Artificielle et à la Data Science. L'objectif principal est de comprendre les dynamiques du marché et de prédire les compétences qui connaîtront une forte croissance dans les prochaines années.

L'analyse prédictive réalisée permet d'exploiter les données historiques collectées afin de détecter les tendances émergentes et d'anticiper les évolutions futures des technologies les plus demandées dans le secteur.


10.1 Construction du dataset temporel


Afin d'analyser l'évolution des compétences technologiques dans le temps, un dataset temporel a été construit à partir des offres d'emploi collectées lors de la phase de Web Content Mining. L'objectif principal de cette étape est de transformer les données brutes en séries temporelles exploitables pour l'analyse prédictive et le forecasting des tendances technologiques.

La construction du dataset temporel a consisté à agréger les occurrences des compétences selon une dimension temporelle basée sur les dates de publication des offres d'emploi. Chaque compétence a ainsi été associée à une fréquence d'apparition pour différentes périodes temporelles, permettant d'observer les variations de popularité des technologies au fil du temps.

Cependant, l'analyse exploratoire des données a révélé un déséquilibre temporel important dans le dataset. Certaines années, notamment 2023, contenaient un volume d'offres largement supérieur aux autres périodes. Ce déséquilibre introduit un biais important dans les analyses temporelles, car les fréquences brutes reflètent davantage le volume de données collectées que la véritable popularité des compétences.

Afin de corriger ce problème, une normalisation des fréquences a été appliquée. Le nombre d'occurrences de chaque compétence a été divisé par le nombre total d'offres disponibles pour chaque période temporelle afin d'obtenir des fréquences relatives exprimées en pourcentage. Cette approche permet de rendre les différentes années comparables malgré les variations importantes du volume de données.





La figure précédente met clairement en évidence le biais présent dans les données brutes. Les courbes de gauche montrent une concentration artificielle des occurrences durant l'année 2023, provoquée par un volume de collecte beaucoup plus important sur cette période. Après normalisation, les courbes obtenues offrent une représentation plus fiable et plus cohérente de l'évolution réelle des compétences technologiques dans le temps.

Cette normalisation permet ainsi d'améliorer la qualité des analyses temporelles et constitue une étape essentielle avant l'application des modèles de forecasting et d'analyse prédictive présentés dans les sections suivantes.


Le dataset temporel final contient principalement :

- la période temporelle,
- le nom de la compétence,
- le nombre d'occurrences observées,
- le volume total d'offres par période,
- la fréquence relative normalisée des compétences.

Cette structure fournit une base robuste pour l'étude des tendances technologiques et l'analyse prospective des compétences les plus demandées dans le marché de l'emploi IA/Data.

10.2 Modèles de forecasting appliqués

10.2.1 Modèle Prophet



Les résultats obtenus mettent en évidence plusieurs dynamiques importantes. Les technologies récentes liées à l'Intelligence Artificielle moderne telles que LLM, MLOps, Databricks et PyTorch présentent des tendances fortement croissantes, traduisant l'évolution rapide du marché vers les architectures IA avancées, les modèles génératifs et les infrastructures MLOps.

À l'inverse, certaines technologies plus établies comme SQL, TensorFlow ou Python montrent des tendances plus stables ou légèrement décroissantes. Ces résultats ne traduisent pas nécessairement une baisse d'utilisation réelle, mais plutôt une maturité plus importante de ces technologies dans l'écosystème informatique.

Les intervalles de confiance générés par Prophet permettent également d'estimer les marges d'incertitude des prévisions. Les zones ombrées représentent ainsi les variations possibles autour des tendances prédites.

Cette analyse fournit une vision prospective des technologies IA/Data susceptibles de connaître la plus forte croissance dans les prochaines années.

10.2.2 Modèle ARIMA

Afin d'évaluer une approche statistique classique de forecasting temporel, le modèle ARIMA (AutoRegressive Integrated Moving Average) a été appliqué sur les séries temporelles issues de Google Trends. ARIMA est l'un des modèles les plus utilisés pour l'analyse et la prédiction des séries chronologiques.

Le modèle utilisé dans ce projet correspond à la configuration ARIMA(2,1,2) :


- $p = 2$: utilisation des deux périodes précédentes pour la prédiction,
- $d = 1$: différenciation de la série afin de supprimer les tendances et rendre la série stationnaire,
- $q = 2$: prise en compte des erreurs de prédiction précédentes.

Cette configuration permet de modéliser les dépendances temporelles des tendances de recherche observées sur Google Trends.

Les données ont été séparées en deux parties :

- période d'entraînement : 2020 à 2024,
- période de test : année 2025.

Le modèle a ensuite été appliqué sur plusieurs compétences majeures du domaine IA/Data telles que Python, PyTorch, TensorFlow, MLOps, LLM et AWS.



Les performances du modèle ont été évaluées à l'aide des métriques MAE (Mean Absolute Error) et R².

Les résultats obtenus montrent que le modèle ARIMA présente des performances variables selon les compétences analysées. Python obtient les meilleurs résultats avec une erreur moyenne relativement faible (MAE = 5.60) et un coefficient R² proche de zéro, indiquant une capacité correcte à suivre les tendances générales de la série temporelle.

À l'inverse, certaines technologies plus récentes ou plus volatiles comme PyTorch, LLM ou MLOps présentent des scores R² négatifs, traduisant une difficulté du modèle ARIMA à capturer les variations rapides et les changements brusques de tendance observés dans les données Google Trends.

Ces résultats s'expliquent principalement par le fait qu'ARIMA repose sur l'hypothèse que les comportements passés se répètent de manière relativement stable dans le futur. Cette hypothèse devient moins adaptée dans le contexte des technologies IA modernes dont les

tendances évoluent très rapidement sous l'effet des innovations récentes et de l'émergence des modèles génératifs.

Malgré ces limites, ARIMA constitue une base statistique de référence utile pour comparer les performances des modèles de forecasting plus avancés comme Prophet.

10.2.3 Régression Linéaire

Afin de disposer d'un modèle de référence simple pour comparer les performances des approches plus avancées, une régression linéaire a également été appliquée sur les séries temporelles Google Trends.

La régression linéaire constitue le modèle prédictif le plus simple. Son objectif est de modéliser l'évolution des données sous la forme d'une droite linéaire :

$$y = a \cdot x + b$$

où :

a représente la pente de la tendance,


b représente la valeur initiale de la série.

Dans ce projet, le temps a été transformé en variable numérique représentant les mois successifs entre 2020 et 2025. Le modèle apprend ainsi une tendance globale moyenne de l'évolution des recherches Google pour chaque compétence technologique.

Les données ont été séparées en deux parties :

période d'entraînement : 2020 à 2024,

période de test : année 2025.



Les résultats obtenus montrent que la régression linéaire permet de capturer les tendances générales des technologies relativement stables comme Python ou AWS. La pente calculée par le modèle permet également d'estimer la direction globale de l'évolution des compétences :

pente positive : technologie en croissance,
pente négative : technologie en diminution.

Cependant, les performances restent limitées pour les technologies présentant des variations rapides ou des changements brusques de tendance comme LLM, MLOps ou PyTorch. Le modèle linéaire suppose en effet une évolution régulière sous forme de droite et ne prend pas en compte les phénomènes de saisonnalité, les ruptures technologiques ou les accélérations soudaines observées dans le domaine de l'Intelligence Artificielle.

Cette approche joue donc principalement le rôle de baseline de référence permettant de comparer les performances des modèles plus sophistiqués comme Prophet et ARIMA.

10.2.4 Comparaison des performances

Modèle	Avantages	Limites
Prophet	Gère tendances complexes et saisonnalité	Plus complexe
ARIMA	Interprétable statistiquement	Difficulté avec ruptures rapides
Régression Linéaire	Simple et rapide	Trop simpliste pour IA moderne

Les résultats obtenus montrent que Prophet offre globalement les prévisions les plus cohérentes pour les séries Google Trends, notamment pour les technologies présentant des évolutions rapides et non linéaires. ARIMA fournit des résultats intermédiaires mais reste limité face aux changements brusques de tendance. Enfin, la régression linéaire constitue une baseline utile mais insuffisante pour modéliser la complexité des tendances technologiques modernes.

Description générale du dashboard

Le dashboard intitulé **“AI & Data Jobs Market Intelligence 2020–2026”** a été réalisé afin d’analyser le marché de l’emploi dans les domaines de l’intelligence artificielle, de la data science, du data engineering, de la business intelligence et des technologies associées. Il s’appuie sur un ensemble de données d’offres d’emploi collectées entre 2020 et 2026, enrichies par une extraction des compétences techniques, des domaines d’expertise, des pays, des modes de travail et des tendances technologiques.

L’objectif principal de ce tableau de bord est de transformer des données brutes d’offres d’emploi en informations exploitables. Il permet de comprendre quels sont les domaines les plus représentés, quelles compétences sont les plus demandées, quelles technologies présentent un potentiel de croissance et comment le Maroc se positionne dans ce marché.

Le dashboard est structuré en quatre pages principales. Chaque page répond à une problématique précise. La première page donne une vue globale du marché. La deuxième page se concentre sur les compétences. La troisième page analyse les tendances futures et les prévisions technologiques. La quatrième page propose un focus sur le Maroc.

Une attention particulière a été portée à l’interprétation des résultats, car les données ne sont pas parfaitement équilibrées. Le dataset contient une forte représentation des États-Unis, un volume important d’offres en 2023, ainsi que des données plus limitées pour certaines années comme 2024 et 2025. Le Maroc est également peu représenté par rapport aux pays dominants. Pour cette raison, certaines visualisations doivent être interprétées comme une observation du dataset collecté, et non comme une représentation exhaustive du marché mondial ou marocain.

Page 1 — Vue globale du marché AI & Data



Objectif de la page

La première page du dashboard présente une vue d'ensemble du marché de l'emploi AI & Data entre 2020 et 2026. Elle permet de comprendre rapidement le volume des données analysées, la diversité géographique des offres, les domaines dominants, les intitulés de postes les plus fréquents et les modes de travail proposés.

Cette page joue un rôle d'introduction. Elle donne au lecteur une vision générale avant d'entrer dans les analyses plus détaillées des compétences et des tendances.

Indicateurs clés

La page commence par quatre indicateurs principaux qui résument le dataset.

Le premier indicateur affiche environ **630K offres d'emploi**. Ce chiffre représente le volume total des offres analysées dans le projet. Il montre que l'étude repose sur une base de données importante, ce qui permet d'obtenir une vision large du marché AI & Data.

Le deuxième indicateur présente **165 pays**. Cela montre que les données couvrent un périmètre international. Cette diversité géographique permet d'analyser la répartition des offres par pays et d'observer les marchés les plus représentés.

Le troisième indicateur affiche **103 compétences distinctes**. Il reflète la richesse technologique du dataset. Les offres d'emploi contiennent plusieurs compétences techniques, ce qui permet d'étudier les technologies les plus demandées.

Le quatrième indicateur présente le pourcentage des offres à distance, avec environ **15,47 % de Remote Jobs**. Cette mesure donne une idée du poids du travail à distance dans les métiers AI & Data.

Répartition des offres par domaine d'expertise

Le graphique circulaire **“Jobs by Expertise Domain”** montre la distribution des offres selon les grands domaines d'expertise. Les domaines les plus représentés sont notamment **Data Engineering, Data Analysis / BI, Machine Learning / AI, Data Science, MLOps / Cloud Data, Other Data / AI** et **Database / Data Warehouse**.

Cette visualisation permet d'identifier les grandes familles de métiers les plus présentes dans le marché. On observe que **Data Engineering** et **Data Analysis / BI** occupent une place importante. Cela signifie que les entreprises recherchent fortement des profils capables de construire des pipelines de données, gérer des bases de données, produire des analyses et créer des tableaux de bord décisionnels.

Le domaine **Machine Learning / AI** est également important, ce qui montre l'intérêt croissant des entreprises pour les modèles prédictifs, l'intelligence artificielle et l'automatisation des processus.

Répartition des offres par pays

Le graphique **“Top Countries by Job Offers”** présente les pays les plus représentés dans le dataset. Les États-Unis apparaissent comme le pays dominant, suivis par des pays comme l'Inde, le Royaume-Uni, l'Allemagne, la France, Singapour et les Pays-Bas.

Cette visualisation est importante car elle montre que le dataset est déséquilibré géographiquement. Les États-Unis ont un poids très élevé dans les données, ce qui peut influencer les résultats globaux. Par conséquent, les analyses globales doivent être interprétées en tenant compte de cette forte représentation américaine.

Distribution géographique des offres

La carte **“Geographic Distribution of Job Offers”** permet de visualiser spatialement la présence des offres d'emploi. Elle donne une représentation géographique globale des données collectées.

Cette carte est surtout utile pour montrer la dimension internationale du projet. Elle complète le graphique des pays en apportant une lecture visuelle de la répartition géographique.

Top des intitulés de postes

Le graphique **“Top Job Titles”** affiche les intitulés de postes les plus fréquents dans les offres. On retrouve des intitulés liés à la data engineering, la data science, l'analyse de données, le

senior data analyst, le machine learning engineer, le MLOps engineer, le prompt engineer, l'AI researcher ou encore le NLP engineer.

Cette visualisation permet d'identifier les profils professionnels les plus demandés. Elle montre que le marché ne se limite pas uniquement aux data scientists, mais couvre plusieurs rôles complémentaires comme les data engineers, data analysts, MLOps engineers et spécialistes IA.

Distribution des modes de travail


Le graphique **“Work Mode Distribution”** montre la répartition des offres selon le mode de travail : **On-site**, **Remote**, **Hybrid** ou **Not specified**.

On observe qu'une grande partie des offres est classée comme **On-site** ou **Not specified**. Les offres à distance existent, mais ne représentent pas la majorité du dataset. Cette information est intéressante car elle montre que, malgré la croissance du télétravail, beaucoup d'offres AI & Data restent encore liées à une présence physique ou ne précisent pas clairement le mode de travail.

Conclusion de la page 1

Cette première page permet de cadrer l'analyse. Elle montre que le marché AI & Data est large, international et dominé par certains domaines comme le Data Engineering, la Data Analysis / BI et le Machine Learning / AI. Elle met aussi en évidence une forte concentration géographique des données, notamment autour des États-Unis.

Page 2 — Analyse des compétences demandées



Objectif de la page

La deuxième page est consacrée à l'analyse des compétences techniques les plus demandées dans les offres d'emploi AI & Data. Elle permet de comprendre quelles technologies, langages, outils et familles de compétences sont les plus présentes dans le marché.

Cette page répond à une question centrale du projet : **quelles compétences faut-il maîtriser pour être compétitif dans les métiers AI & Data ?**

Indicateurs clés

La page présente plusieurs indicateurs synthétiques.

Le premier indicateur affiche **91 compétences distinctes**. Cela représente le nombre de compétences réellement utilisées dans cette page après nettoyage et préparation des données.

Le deuxième indicateur montre environ **3M de mentions de compétences**. Cela signifie que les compétences apparaissent plusieurs fois dans les offres, car une même offre peut contenir plusieurs skills.

Le troisième indicateur affiche une **croissance moyenne prédite de 9,65**. Cette mesure relie la page des compétences à la partie prévisionnelle du dashboard. Elle donne une indication sur la dynamique future moyenne des compétences analysées.

Le quatrième indicateur indique que la compétence la plus présente est **SQL**. Cela confirme le rôle central de SQL dans les métiers de la data, notamment pour l'interrogation, la manipulation et l'exploitation des bases de données.

Top 15 des compétences les plus demandées

Le graphique "**Top 15 Most Requested Skills**" présente les compétences les plus fréquentes dans les offres. Les deux compétences dominantes sont **SQL** et **Python**, avec des parts proches de 13 %. Ces deux compétences apparaissent comme les fondations principales du marché AI & Data.

SQL est essentiel pour travailler avec les bases de données, extraire des informations et réaliser des analyses. Python est largement utilisé pour l'analyse de données, le machine learning, l'automatisation, le traitement de texte, le deep learning et le développement d'applications data.

D'autres compétences importantes apparaissent ensuite, comme **AWS, R, Tableau, Excel, Azure, Spark, Power BI** et **TensorFlow**. Ces résultats montrent que le marché demande à la fois des compétences en programmation, cloud computing, visualisation de données, big data et intelligence artificielle.

Répartition des catégories de compétences par domaine métier

La visualisation **“Skill Category Mix by Job Domain”** est l’une des plus riches de cette page. Elle montre comment les catégories de compétences se répartissent selon les types de postes.

Par exemple, les métiers de **Data Engineer** sont fortement associés aux compétences de programmation, cloud, DevOps et big data. Les métiers de **Data Analyst** sont davantage liés aux compétences d’analyse de données, de BI et de visualisation. Les métiers de **Data Scientist** combinent des compétences en programmation, machine learning, analyse de données et statistiques.

Cette visualisation est importante parce qu’elle montre que les compétences ne sont pas demandées de la même manière selon les métiers. Elle permet donc une lecture plus fine du marché.

Répartition des compétences par catégorie

La treemap **“Skill Demand by Category”** permet de visualiser les grandes familles de compétences. Les catégories visibles incluent la programmation, le cloud/devops, l’AI/Machine Learning, le big data, la data analysis/BI, les bases de données et d’autres domaines techniques.

Cette visualisation permet de comprendre la structure globale des compétences. Elle montre que les métiers AI & Data exigent une combinaison de compétences techniques. Il ne suffit pas de connaître un seul outil : les profils les plus recherchés combinent souvent programmation, bases de données, cloud, analyse et machine learning.

Tableau de classement des compétences

Le tableau **“Skill Ranking and Market Share”** présente le classement détaillé des compétences avec leur catégorie, leur nombre de mentions et leur part de marché.


Ce tableau est utile pour le rapport car il donne des valeurs exactes. Il permet de compléter les graphiques par une lecture quantitative précise. Par exemple, il montre que SQL et Python dominant largement, suivis par AWS, R, Tableau, Excel et d’autres technologies.

Conclusion de la page 2

Cette page montre que les compétences les plus importantes du marché AI & Data sont à la fois des compétences fondamentales et des compétences spécialisées. SQL et Python restent incontournables, tandis que les outils cloud, BI, big data et machine learning complètent le profil des candidats recherchés.

Elle met aussi en évidence que les compétences doivent être analysées selon les métiers. Un Data Analyst, un Data Engineer et un Machine Learning Engineer n’ont pas exactement les mêmes besoins techniques.

Page 3 — Tendances futures et prévisions technologiques



Objectif de la page

La troisième page est dédiée aux tendances technologiques futures. Elle vise à identifier les compétences qui présentent une dynamique positive, celles qui sont à surveiller et celles qui semblent perdre en croissance relative.

Cette page apporte une dimension stratégique au projet. Elle ne se contente pas d'analyser le marché actuel, mais cherche à anticiper les évolutions possibles des compétences AI & Data.

Méthodologie générale

Les résultats de cette page sont présentés comme une **estimation stratégique**. Ils s'appuient sur trois éléments : les données du marché Kaggle, les tendances Google Trends et un modèle de forecasting temporel basé sur Prophet.

Cette combinaison permet de croiser la présence actuelle d'une compétence dans les offres d'emploi avec son intérêt technologique dans le temps et son évolution prédite. Ainsi, la page ne mesure pas seulement ce qui est populaire aujourd'hui, mais aussi ce qui pourrait devenir important demain.

Indicateurs clés

La page contient plusieurs indicateurs décisionnels.

Le premier indicateur présente une **croissance moyenne prédite de 9,65**. Il résume la tendance moyenne des compétences analysées.

Le deuxième indicateur affiche **4 technologies stratégiques**. Ces technologies sont celles qui présentent une forte dynamique de croissance et qui méritent une attention particulière.

Le troisième indicateur indique **LLM** comme compétence émergente. Cela signifie que les modèles de langage et les technologies liées à l'IA générative apparaissent comme un axe important pour l'avenir.

Le quatrième indicateur présente un **score moyen Google Trends de 20,26**, qui mesure l'intérêt moyen observé sur les tendances de recherche.

Priorités technologiques futures

Le graphique "**Priorités technologiques futures**" classe les technologies selon leur niveau de priorité : stratégique, recommandé, surveiller ou attention.

Les compétences classées comme **stratégiques** sont celles qui présentent une forte hausse prédite. Elles représentent des opportunités importantes pour les professionnels, les étudiants et les entreprises. Dans ton dashboard, des technologies comme **LLM, MLOps, Databricks** et **AWS** ressortent comme stratégiques.

Les compétences classées comme **à surveiller** restent importantes mais montrent une dynamique moins forte. Les compétences classées en **attention** peuvent être en baisse relative ou perdre de la croissance.

Prévisions stratégiques des compétences

Le tableau "**Prévisions stratégiques des compétences**" donne une lecture détaillée de chaque compétence analysée. Il présente la priorité, la compétence, la tendance et la variation prédite.

On observe que **LLM, Databricks, MLOps** et **AWS** sont en forte hausse. Ces résultats sont cohérents avec l'évolution actuelle du marché, où l'IA générative, l'industrialisation des modèles, le cloud et les plateformes de données modernes prennent de plus en plus d'importance.

À l'inverse, certaines compétences comme **SQL, TensorFlow** ou **Python** peuvent afficher une baisse relative. Cela ne signifie pas qu'elles deviennent inutiles. Cela signifie plutôt qu'elles sont déjà très matures et largement installées. Leur croissance peut ralentir parce qu'elles sont déjà très présentes dans le marché.

Évolution future estimée des compétences

Le graphique horizontal “**Évolution future estimée des compétences**” permet de visualiser rapidement les compétences en hausse et celles en baisse.

Les barres positives montrent les compétences dont la variation prédite est favorable. Les compétences comme **LLM**, **Databricks**, **MLOps** et **AWS** apparaissent clairement comme des technologies en forte progression.

Les barres négatives indiquent les compétences dont la croissance prédite est plus faible ou en baisse relative, comme **SQL**, **TensorFlow** ou **Python**.

Cette visualisation est efficace car elle permet une lecture rapide des priorités technologiques.

Évolution des tendances technologiques

Le graphique “**Évolution des tendances technologiques**” montre l’évolution de plusieurs technologies dans le temps, entre 2020 et 2025. Il permet de comparer la dynamique de compétences comme Docker, Power BI, Python, PyTorch ou SQL.


Cette visualisation complète les prévisions en montrant l’historique des tendances. Elle permet de distinguer les technologies stables, les technologies en progression et celles qui connaissent une baisse relative.

Conclusion de la page 3

Cette page montre que le marché AI & Data évolue vers des technologies plus avancées et plus industrialisées. Les compétences liées aux **LLM**, au **MLOps**, au **cloud** et aux plateformes modernes comme **Databricks** apparaissent comme des axes stratégiques.

Cependant, les compétences fondamentales comme SQL et Python restent importantes. Même si leur croissance prédite peut être plus faible, elles demeurent des bases essentielles pour les métiers de la data.

Page 4 — Focus Maroc



Objectif de la page

La quatrième page est consacrée à l'analyse du Maroc. Elle vise à comprendre la présence des offres AI & Data marocaines dans le dataset, les domaines les plus représentés au Maroc, les compétences les plus visibles et la comparaison du Maroc avec d'autres pays.

Cette page est importante parce qu'elle contextualise l'analyse globale dans un marché local. Elle permet de voir comment le Maroc apparaît dans les données collectées.

Précaution méthodologique

Le Maroc représente une petite partie du dataset. La carte indique une **part du Maroc de 0,17 %**. Cela signifie que les offres marocaines sont peu nombreuses par rapport aux offres globales, surtout par rapport aux États-Unis.

Il faut donc interpréter cette page avec prudence. Les résultats ne doivent pas être présentés comme une image complète du marché marocain, mais comme une **présence observée dans les données collectées**.

Cette précision est très importante dans le rapport, car les données marocaines sont limitées et concentrées sur certaines années, notamment 2023 et 2026.

Part du Maroc

L'indicateur "**Part du Maroc**" montre que le Maroc représente environ **0,17 %** du dataset global. Cette valeur confirme que le Maroc est faiblement représenté dans les données.

Cet indicateur permet de justifier une lecture prudente. Il montre aussi pourquoi il est nécessaire de séparer le focus Maroc de l'analyse globale.

Domaine dominant au Maroc

L'indicateur “**Domaine dominant**” affiche **Data Engineering** comme domaine principal au Maroc. Cela signifie que, dans les offres marocaines observées, les profils liés à l'ingénierie des données sont les plus représentés.

Ce résultat peut indiquer une demande pour des compétences liées à la préparation des données, la construction de pipelines, l'intégration de données, les bases de données, le cloud et les architectures data.

Nombre d'offres Maroc

L'indicateur “**Offres Maroc**” affiche environ **1K offres**. Ce chiffre représente le volume d'offres marocaines présentes dans le dataset.

Même si ce volume est faible par rapport au total global, il permet tout de même d'effectuer une analyse descriptive du marché marocain observé.

Présence observée des offres Maroc par année

Le graphique “**Présence observée des offres Maroc par année**” montre la répartition des offres marocaines selon les années.

On observe une forte concentration en **2023**, puis une présence plus faible en **2026** et très limitée en **2025**. Cette visualisation montre que les données marocaines ne sont pas équilibrées dans le temps.

Le choix du titre “présence observée” est pertinent, car il évite de présenter cette visualisation comme une évolution réelle du marché. Il s'agit plutôt de montrer comment les offres marocaines sont réparties dans le dataset collecté.

Top compétences demandées au Maroc

Le graphique “**Top compétences demandées au Maroc**” vise à afficher les compétences les plus présentes dans les offres marocaines. Il permet de comprendre quelles technologies apparaissent le plus souvent dans les offres associées au Maroc.

Cette visualisation est utile pour identifier les compétences importantes dans le contexte marocain. Elle permet de voir si les besoins locaux sont plutôt orientés vers SQL, Python, cloud, BI, machine learning ou data engineering.

Cependant, il faut vérifier que ce graphique est bien filtré sur le Maroc. Les valeurs affichées doivent correspondre uniquement aux offres marocaines. Si les valeurs sont trop proches des valeurs globales, cela signifie que le filtre Maroc n'est pas correctement appliqué.

Comparaison Maroc avec d'autres pays

Le graphique **"Jobs % by Country par expertise_domain and country"** compare la répartition des domaines AI & Data entre plusieurs pays, notamment le Maroc, les États-Unis, la France et le Canada.

L'utilisation du pourcentage est très pertinente, car les volumes d'offres sont très différents entre les pays. Comparer les nombres bruts aurait donné un avantage automatique aux pays les plus représentés, comme les États-Unis. Les pourcentages permettent donc de comparer la structure des marchés plutôt que leur taille.

Cette visualisation montre comment les offres se répartissent par domaine dans chaque pays. Elle permet d'observer si le Maroc est davantage orienté vers le Data Engineering, la Data Analysis / BI, le Machine Learning / AI ou le MLOps / Cloud Data.

Répartition des domaines AI/Data au Maroc

Le graphique **"Répartition des domaines AI/Data au Maroc"** montre les domaines les plus représentés dans les offres marocaines.

On observe que **Data Engineering** arrive en première position, suivi par **Data Analysis / BI, MLOps / Cloud Data, Machine Learning / AI, Data Science, Other Data / AI** et **Database / Data Warehouse**.

Cette répartition montre que le marché marocain observé est fortement orienté vers les métiers liés à l'exploitation et à l'ingénierie des données. Les entreprises semblent rechercher des profils capables de gérer des données, de construire des systèmes data, d'utiliser des outils analytiques et de contribuer à des projets AI/Data.

Conclusion de la page 4

La page Maroc apporte une valeur importante au dashboard, car elle permet de relier l'analyse globale à un contexte local. Elle montre que le Maroc est faiblement représenté dans le dataset, mais que les offres observées indiquent une orientation vers le Data Engineering, l'analyse de données, le cloud data et le machine learning.

La page doit être interprétée avec prudence à cause du déséquilibre des données. Elle ne représente pas tout le marché marocain, mais elle donne une vision utile des offres marocaines disponibles dans le dataset.

Conclusion générale du dashboard

Le dashboard final permet d'analyser le marché de l'emploi AI & Data selon quatre axes complémentaires.

La première page donne une vision globale du marché, en présentant le volume des offres, les pays les plus représentés, les domaines dominants, les intitulés de postes et les modes de travail.

La deuxième page approfondit l'analyse des compétences. Elle montre que SQL et Python restent les compétences les plus demandées, tandis que les outils cloud, BI, big data et machine learning jouent également un rôle important.

La troisième page ajoute une dimension prospective. Elle identifie les technologies à fort potentiel de croissance, notamment LLM, MLOps, Databricks et AWS. Elle permet de distinguer les compétences fondamentales des compétences émergentes.

La quatrième page propose un focus spécifique sur le Maroc. Elle montre que le Maroc représente une faible part du dataset, mais que les offres marocaines observées sont surtout orientées vers le Data Engineering, la Data Analysis / BI, le MLOps / Cloud Data et le Machine Learning / AI.

Interprétation globale et conclusion finale

À partir de l'analyse réalisée dans notre dashboard AI & Data Jobs Market Intelligence 2020–2026, nous pouvons conclure que le marché de l'emploi dans les domaines de l'intelligence artificielle et de la data est fortement dynamique, diversifié et en évolution continue

D'abord, les résultats montrent que les métiers de la data ne se limitent pas uniquement au rôle de Data Scientist. Nous observons une forte présence des domaines Data Engineering, Data Analysis / BI, Machine Learning / AI et Data Science. Cela signifie que les entreprises recherchent aujourd'hui des profils capables non seulement de développer des modèles d'intelligence artificielle, mais aussi de collecter, préparer, organiser, analyser et valoriser les données.

Ensuite, l'analyse des compétences montre que SQL et Python restent les compétences les plus importantes du marché. SQL est indispensable pour travailler avec les bases de données, tandis que Python est essentiel pour l'analyse de données, le machine learning, l'automatisation et l'intelligence artificielle. Nous remarquons également l'importance des compétences liées au cloud, à la business intelligence, au big data et au machine learning, comme AWS, Azure, Spark, Power BI, Tableau et TensorFlow. Cela montre que les profils les plus recherchés sont des profils polyvalents, capables de combiner plusieurs compétences techniques.

La partie forecasting nous permet d'aller plus loin en identifiant les technologies qui peuvent devenir stratégiques dans les prochaines années. Les résultats indiquent que des compétences comme LLM, MLOps, Databricks et AWS présentent un fort potentiel de croissance. Nous

pouvons donc conclure que le marché évolue vers des technologies plus avancées, liées à l'IA générative, à l'industrialisation des modèles, au cloud et aux plateformes modernes de traitement des données.

Concernant le Maroc, notre analyse montre que sa présence dans le dataset reste faible par rapport aux pays dominants, notamment les États-Unis. La part du Maroc est limitée, ce qui nous oblige à interpréter les résultats avec prudence. Cependant, les offres marocaines observées montrent une orientation claire vers Data Engineering, Data Analysis / BI, MLOps / Cloud Data et Machine Learning / AI. Cela indique que le marché marocain commence à suivre les grandes tendances internationales, surtout autour de l'ingénierie des données, de l'analyse, du cloud et de l'intelligence artificielle.

Il est aussi important de rappeler que notre dataset n'est pas parfaitement équilibré. Les États-Unis sont très représentés, certaines années comme 2023 contiennent beaucoup plus de données, alors que d'autres années sont moins présentes. Pour le Maroc, les données sont surtout concentrées sur certaines années. Donc, nos résultats doivent être compris comme une analyse des données collectées, et non comme une représentation complète de tout le marché mondial ou marocain.

En conclusion, ce projet nous a permis de transformer des données d'offres d'emploi en informations utiles pour comprendre le marché AI & Data. Le dashboard montre que les compétences fondamentales comme SQL et Python restent indispensables, mais que les compétences émergentes comme LLM, MLOps, Databricks et les technologies cloud deviennent de plus en plus stratégiques. Pour les étudiants, les professionnels et les organismes de formation, ces résultats peuvent aider à mieux orienter les choix de formation, de spécialisation et de veille technologique.

Ainsi, notre dashboard constitue un outil d'aide à la décision qui permet de mieux comprendre les besoins actuels du marché et d'anticiper les compétences à développer pour l'avenir dans les métiers de la data et de l'intelligence artificielle.